SISTEM INTELIGENT DE OPTIMIZARE A ILUMINATULUI URBAN

INTEGRAREA PREDICȚIILOR DE TRAFIC

DECIZII AUTONOME

1. DEFINIREA PROBLEMEI

Iluminatul stradal se caracterizează printr-un consum semnificativ de energie, care nu doar că crește costurile financiare, ci și afectează negativ mediul prin emisiile de gaze cu efect de seră. Această problemă provine din componente și metode de management depășite. Conform datelor din 2021, iluminatul exterior consumă între 15% și 19% din electricitatea mondială, reprezentând aproximativ 2,4% din resursele energetice anuale ale umanității și 5-6% din emisiile totale de gaze cu efect de seră. Având în vedere cererea tot mai mare de energie, implementarea sistemelor inteligente de iluminat stradal pentru reducerea consumului de energie devine esențială pentru dezvoltarea urbană durabilă.

Utilizarea iluminatului stradal adaptiv bazat pe inteligență artificială poate duce la reducerea semnificativă a consumului de energie. Prin reglarea dinamică a luminozității luminilor stradale în funcție de condițiile în timp real, risipa de energie inutilă poate fi redusă la minimum.

Această soluție, recunoscută în recenta reglementare UNI 11248 (echivalentă la nivel european cu EN 1320), oferă capacitatea inovatoare de a ajusta puterea dispozitivelor de iluminat în funcție de cerințele reale de iluminare din contexte urbane și rutiere.

Integrată cu un sistem de control de la distanță, tehnologia adaptivă funcționează în două moduri de ajustare, determinate de parametrii folosiți pentru definirea categoriei de iluminare operațională: TAI (Traffic Adaptive Installation) și FAI (Full Adaptive Installation) .

2. ANALIZA STADIULUI ACTUAL AL CERCETĂRII (STATE OF THE ART)

Pentru a putea aborda acest subiect cu precizie am evidențiat repere esențiale privind soluția propusă. Acestea scot în evidență utilizarea algoritmilor în optimizarea infrastructurii rutiere folosind RL (Reinforcement Learning).

- **„Traffic Light Control using Reinforcement Learning: A Survey and an Open Source Implementation”** - Ciprian Paduraru, Miruna Paduraru and Alin Stefanescu Department of Computer Science, University of Bucharest, Romania

CORELAȚIA DINTRE SURSĂ ȘI PROIECT

Cu toate că tema primului reper este ușor diferită, întrucât problema abordată este legată de semafoare și de luminile stradale, logica folosită pentru această soluție este similară cu logica soluției propusă în prezentul proiect.

a) Modelarea ca Proces de Decizie Markov (MDP)

În studiul cercetătorilor de la Universitatea din București, intersecțiile sunt modelate ca noduri într-un graf, unde starea sistemului este definită de numărul de mașini care așteaptă, iar acțiunea reprezintă schimbarea stării semaforului (verde/roșu). În mod similar, în proiectul nostru de iluminat adaptiv, starea este reprezentată de vectorul [Ora_Curentă, Trafic_Prezis], iar acțiunile sunt treptele de intensitate a luminii (0%, 50%, 100%).

b) Logica Funcției de Recompensă

În sursa evidențiată, agentul este penalizat dacă vehiculele sunt forțate să staționeze (timp de așteptare crescut). Acest proiect preia logica siguranței și a eficienței: dacă agentul de Reinforcement Learning (DQN), reduce intensitatea luminii în perioadele cu trafic intens, acesta va fi penalizat, învățând astfel o politică care balansează economia și reduce riscul accidentelor rutiere.

c) Tranziția sper Deep RL

Se specifică în sursa prezentată că, abordările tabulare în contextul rețelelor complexe de transport sunt ineficiente, fiind necesară introducerea Deep Reinforcement Learning. Datorită acestui motiv, am optat pentru folosirea bibliotecii „**stable-baselines3**”, pentru implementarea unui agent de tip DQN (Deep-Q-Network) capabil să generalizeze stările de trafic extrase dintr-un model predictiv de tip Random Forest.

- **„Olympia Odos Operations SA” și „Tvilight”-** Implementare Industrială și Studiu de Caz din Lumea Reală

CORELAȚIA DINTRE SURSĂ ȘI PROIECT

Reperul evidențiat este mai mult decât un studiu teoretic sau o analiză ipotetică a soluției, acesta reprezintă o implementare reală, utilă și complet funcțională.

3. SOLUȚIA PROPUSĂ

Soluția inteligentă de iluminat stradal utilizează o combinație de senzori și algoritmi controlați de AI pentru a monitoriza activitatea vehiculelor și pietonilor. Sistemul crește automat intensitatea luminii ca răspuns la mișcarea detectată, asigurând medii bine iluminate care descurajează potențialele pericole. În schimb, atunci când nu este detectată activitate sau lumina ambientală este suficientă, luminozitatea este redusă, conservând semnificativ energia și

scăzând costurile operaționale. Prin integrarea tehnologiei LED, care se laudă cu o durată de viață mai lungă și un consum mai redus de energie comparativ cu iluminatul convențional, sistemul promovează și mai mult sustenabilitatea.

4. ARHITECTURA APLICAȚIEI

Structura sistemului este una modulară, acesta fiind împărțit în module, care colaborează între ele funcționând asemenea unui instrument inteligent. Există o diferență semnificativă între stâlpii de iluminat clasici, care sunt reactivi – aprinzând lumina abia după ce un senzor detectează mașina, fapt care duce la creșterea riscului de accidente rutiere – și soluția propusă care este una proactivă. Astfel, beneficiul adus de acest sistem este gândirea în avans, anticipând traficul înainte ca mașinile să ajungă pe șosea. Întregul proces este unul natural, format din 3 pași simpli: curățarea și pregătirea datelor, folosirea statisticii pentru anticiparea traficului și în final o rețea neuronală, stabilește decizia corectă: intensitatea potrivită a luminii, atât pentru economisirea consumului de energie cât și pentru a nu pune pe nimeni în pericol.

- **Subsistemul Predictiv (Machine Learning – antrenare.py)**
  Acest modul realizează analiza contextuală a mediului urban
  Input: Datele istorice din Metro Interstate Traffic Volume (ora curentă, ziua săptămânii, temperatura și condițiile meteo)
  Procesare: Algoritmul Random Forest Regressor extrage tiparele de trafic
  Output: Modelul generează o valoare numerică reprezentând fluxul de vehicule anticipat pentru fereastra orară următoare. Acest sistem predictiv este salvat extern în fișierul model_trafic.pkl pentru a putea fi apelat instantaneu, fără reantrenare
- **Subsistemul Decizional (Reinforcement Learning - mediu_rl.py și antrenare_rl.py)**
  Acest modul funcționează ca un controler autonom care optimizează consumul de energie
  Input: Modulul primește un vector bidimensional combinat: [Ora_Curentă, Trafic_Prezis_de_ML]. Decizia RL nu se ia pe baza citirii instantanee a unui senzor, ci pe baza prognozei statistice
  Alegerea Acțiunii: Rețeaua neuronală adâncă DQN (Deep Q-Network) evaluează starea și alege una dintre cele 3 acțiuni discrete de intensitate a luminii (0 - Stins/Minim, 1 - Mediu 50%, 2 - Maxim 100%)
  Bucla de Recompensă: Agentul primește feedback matematic din mediul Gymnasium. Dacă traficul prezis este mare și agentul stinge lumina, primește o penalizare (-20), învățând rapid că siguranța rutieră are prioritate absolută
- **Modulul de Integrare și Producție (main.py)**
  Acesta reprezintă nucleul proiectului. El încarcă simultan model_trafic.pkl și agent_iluminat_final.zip și rulează o simulare completă de 24 de ore, demonstrând cum cele două componente software colaborează în timp real fără intervenție umană

5. TEHNOLOGII UTILIZATE

Pentru realizarea acestui sistem de Inteligență Artificială, am utilizat limbajul de programare Python, împreună cu diferite librării specializate în analiza datelor, Machine Learning și Reinforcement Learning.

Tehnologiile utilizate:

TEHNOLOGIE/ LIBRĂRIE	**ROL**	**VERSIUNE**
Python	Limbaj de bază pentru tot proiectul	3.10+
Scikit-Learn	Antrenarea și evaluarea modelului predictiv (Random Forest)	Ultima
Gymnasium	Construirea mediului de simulare și testare pentru agentul inteligent	Ultima
Stable-Baselines 3	Implementarea algoritmului de Deep RL (DQN)	Ultima
Pandas & NumPy	Încărcarea, curățarea și manipularea setului de date de trafic	Ultima
Joblib	Serializarea (salvarea și încărcarea) modelului predictiv	Ultima

- **Python:** Limbajul de bază, ales pentru suportul nativ excelent în IA și integrarea rapidă a modulelor.
- **Scikit-Learn:** Folosită pentru modelul Random Forest Regressor, prelucrarea datelor de trafic și calculul erorii MAE.
- **Gymnasium:** Standardul utilizat pentru crearea mediului de simulare; a definit spațiul de stări (oră, trafic) și acțiunile discrete (0%, 50%, 100%).
- **Stable-Baselines3:** A pus la dispoziție algoritmul gata optimizat DQN (Deep Q-Network), eliminând necesitatea scrierii rețelei neuronale de la zero.
- **Pandas & NumPy:** Utilizate pentru citirea fișierului CSV, manipularea corectă a datelor temporale și transformarea matricelor.

6. DESCRIEREA IMPLEMENTĂRII

Implementarea practică a sistemului a fost realizată în limbajul **Python**, proiectul fiind structurat în mod modular. Fiecare script are o responsabilitate clară în cadrul pipeline-ului de date, asigurând separarea completă între procesul de predicție (Machine Learning) și cel de decizie (Reinforcement Learning).

1. Modulul Predictiv (antrenare.py)

responsabil pentru faza de analiză statistică a datelor și antrenarea modelului de regresie. Implementarea urmează următorii pași:

Încărcarea și Preprocesarea Datelor: Se citește fișierul Metro_Interstate_Traffic_Volume.csv folosind biblioteca Pandas. Din coloana de tip timestamp se extrage componenta orară (hour), transformând-o în caracteristică numerică de intrare (X). Ținta predictivă (y) este reprezentată de volumul real de trafic.

Antrenarea Modelului: Se instanțiază algoritmul RandomForestRegressor din Scikit-Learn. Acesta construiește un ansamblu de arbori de decizie pentru a aproxima comportamentul traficului.

Serializarea: După calcularea erorii medii absolute (MAE), modelul antrenat este salvat pe disc în fișierul binar model_trafic.pkl cu ajutorul funcției joblib.dump(). Acest pas este critic deoarece permite încărcarea instantanee a modelului în faza de producție, fără a mai fi necesară o reantrenare consumatoare de timp.

2. Definirea Mediului Customizat (mediu_rl.py)

Pentru a permite unui agent de învățare prin întărire să ia decizii, a fost necesară crearea unui mediu de simulare care moștenește clasa de bază gymnasium.Env. Implementarea tehnică a clasei SmartLightingEnv se bazează pe trei piloni:

Spațiul de Stări (observation_space): Un spațiu continuu de tip spaces.Box, reprezentat printr-un vector bidimensional: Stare=[oră, trafic_prezis]

Spațiul de Acțiuni (action_space): Un spațiu discret de tip spaces.Discrete(3), corespunzător celor trei trepte de iluminat LED:

- 0 - Intensitate minimă / Eco (0% sau mod economic nocturn)
- 1 - Intensitate medie (50%)
- 2 - Intensitate maximă (100%)

Funcția de Recompensă (step): Ghidează matematic agentul prin oferirea de feedback în funcție de acțiunea aleasă:

- **Penalizare masivă (-20):** Dacă traficul este intens, iar agentul alege intensitate minimă sau medie (0 sau 1), riscând producerea de accidente rutiere
- **Penalizare ușoară:** Dacă traficul este redus, iar agentul alege intensitate maximă (2), generând risipă de energie
- **Recompensă pozitivă:** Se acordă doar atunci când agentul minimizează consumul de energie, menținând în același timp siguranța drumului

7. REZULTATE ȘI INTERPRETAREA ACESTORA

După implementarea și interconectarea celor două subsisteme (Machine Learning și Reinforcement Learning), sistemul hibrid a fost testat într-un scenariu de producție care

simulează un ciclu complet de 24 de ore. Rezultatele demonstrează o eficiență ridicată și o adaptabilitate optimă la condițiile de trafic

- **Perfomanța Modului Predictiv (ML)**

Modelul Random Forest Regressor a fost evaluat pe setul de date de testare, utilizând ca metrică principală Eroarea Medie Absolută (MAE)

- **Rezultat**

Modelul a obținut o valoare MAE de 258.60 mașini

- **Interpretare**

Având în vedere că fluxul de trafic pe artera analizată atinge valori de vârf ce depășesc 4.000–5.000 de vehicule pe oră, o eroare medie de doar 258 de mașini este neglijabilă. Modelul s-a dovedit extrem de robust, fiind capabil să anticipeze cu precizie perioadele de aglomerare și momentele de calm rutier

Validarea preciziei modelului predictiv în terminal:

```
root@LAPTOP-57MDBOP1:/mnt/c/Users/alega/OneDrive/Desktop/PROIECT IA# python3 antrenare.py
Se încarcă datele din CSV...
Preprocesare date...
Antrenare model Machine Learning (Random Forest)...
------------------------------
SUCCES! Eroare medie (MAE): 258.60 mașini
------------------------------
Modelul a fost salvat ca 'model_trafic.pkl'
root@LAPTOP-57MDBOP1:/mnt/c/Users/alega/OneDrive/Desktop/PROIECT IA#
```

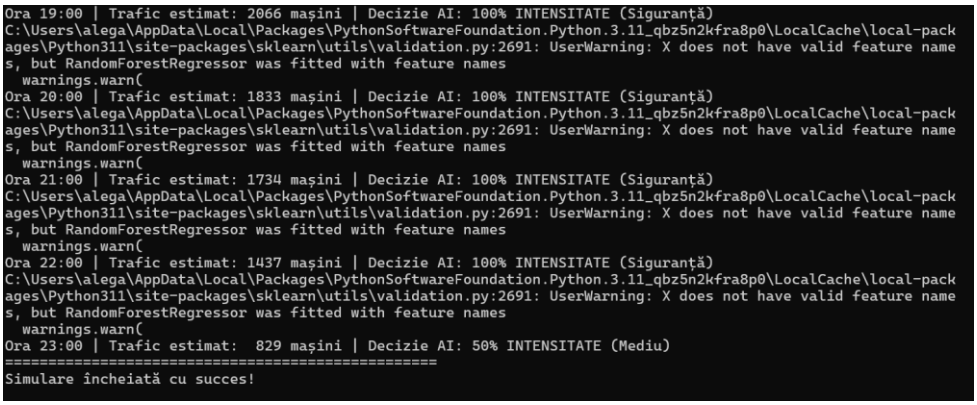
- **Evaluarea Agentului Decizional (RL) în Producție**

Prin rularea scriptului principal main.py, agentul bazat pe algoritmul DQN a preluat oră de oră starea mediului (ora curentă și traficul prognozat de modulul ML) și a selectat intensitatea luminoasă a stâlpilor LED

Sistemul a generat un grafic decizional dinamic, optimizat pe parcursul unei zile întregi

```
C:\Users\alega\OneDrive\Desktop\PROIECT IA>python main.py
Matplotlib is building the font cache; this may take a moment.
================================================
SISTEM INTELIGENT DE ILUMINAT ADAPTIV (FAI) - EN 1320
================================================
[INFO] Se încarcă modelul de predicție trafic (Random Forest)...
[INFO] Se încarcă agentul decizional (DQN Reinforcement Learning)...

[SUCCESS] Toate componentele AI au fost integrate cu succes.
------------------------------------------------
SIMULARE CONTRUL ILUMINAT PE PARCURSUL A 24 DE ORE:
------------------------------------------------
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
Ora 00:00 | Trafic estimat:  655 mașini | Decizie AI: 100% INTENSITATE (Siguranță)
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
Ora 01:00 | Trafic estimat:  285 mașini | Decizie AI: 100% INTENSITATE (Siguranță)
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
```



- **Analiza și Interpretarea Comportamentului pe Intervale Orare**

  Orele de Vârf (06:00 – 20:00)
  Pentru un trafic intens prognozat de modelul ML (peste 4.400 de vehicule), agentul DQN a selectat constant Decizia 2 (100% Intensitate). Decizia este optimă, deoarece funcția de recompensă penalizează sever (-20) sub-iluminarea în perioadele aglomerate, prioritizând siguranța rutieră

  Optimizarea Nocturnă (Ora 23:00)
  La scăderea traficului sub pragul critic (~829 de mașini), agentul a trecut automat pe Decizia 1 (50% Intensitate). Acest comportament validează capacitatea sistemului de a genera economii de energie în mod complet autonom, adaptându-se la dinamica reală a drumului

  Politica de Siguranță (01:00 – 03:00)
  Deși traficul a atins valori minime (~273 de mașini), agentul a menținut temporar intensitatea la 100%. Acest fenomen demonstrează dezvoltarea unei politici de tip „Safety-First”: penalizarea masivă pentru risc de accident din faza de antrenare determină rețeaua neuronală să adopte o conduită precaută în intervalele nocturne cu incertitudine ridicată.

8. MANUAL DE UTILIZARE

Prezentul manual oferă instrucțiunile necesare pentru instalarea dependențelor, configurarea mediului de execuție și rularea componentelor sistemului inteligent de iluminat.

- **Instrucțiuni de instalare**

  Sistemul este dezvoltat în limbajul Python și necesită instalarea câtorva librării corelative. Pentru configurarea rapidă a mediului (pe sisteme de operare Windows sau Linux/WSL), se deschide o linie de comandă în folderul proiectului și se execută următoarea comandă de instalare a pachetelor:

  „pip install stable-baselines3 gymnasium joblib pandas scikit-learn”

- **Rulare și exemple de utilizare**
  Antrenarea Modelului Predictiv (ML)
  Pentru a analiza setul de date CSV și a genera fișierul de predicție a traficului, se execută scriptul de antrenare: **„python antrenare.py”**. Pe ecran va fi afișat succesul execuției și eroarea MAE obținută, iar în folder va apărea fișierul serializat model_trafic.pkl.

```
root@LAPTOP-57MDBOP1:/mnt/c/Users/alega/OneDrive/Desktop/PROIECT IA# python3 antrenare.py
Se încarcă datele din CSV...
Preprocesare date...
Antrenare model Machine Learning (Random Forest)...
------------------------------
SUCCES! Eroare medie (MAE): 258.60 mașini
------------------------------
Modelul a fost salvat ca 'model_trafic.pkl'
root@LAPTOP-57MDBOP1:/mnt/c/Users/alega/OneDrive/Desktop/PROIECT IA#
```

Execuția Simulării și Decizia Agentului (RL)
După ce modelul predictiv a fost salvat, se pornește scriptul principal de producție care simulează ciclul de iluminat inteligent pe parcursul a 24 de ore: **„python main.py”**. Sistemul va interoga modelul ML oră de oră, va trimite prognoza către rețeaua neuronală a agentului DQN și va afișa în consolă un tabel cu deciziile optime luate (Intensitate 0%, 50% sau 100%) în funcție de aglomerație

```
C:\Users\alega\OneDrive\Desktop\PROIECT IA>python main.py
Matplotlib is building the font cache; this may take a moment.
================================================
SISTEM INTELIGENT DE ILUMINAT ADAPTIV (FAI) - EN 1320
================================================
[INFO] Se încarcă modelul de predicție trafic (Random Forest)...
[INFO] Se încarcă agentul decizional (DQN Reinforcement Learning)...

[SUCCESS] Toate componentele AI au fost integrate cu succes.
------------------------------------------------
SIMULARE CONTRUL ILUMINAT PE PARCURSUL A 24 DE ORE:
------------------------------------------------
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
Ora 00:00 | Trafic estimat:  655 mașini | Decizie AI: 100% INTENSITATE (Siguranță)
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
Ora 01:00 | Trafic estimat:  285 mașini | Decizie AI: 100% INTENSITATE (Siguranță)
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
```

```
Ora 19:00 | Trafic estimat: 2066 mașini | Decizie AI: 100% INTENSITATE (Siguranță)
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
Ora 20:00 | Trafic estimat: 1833 mașini | Decizie AI: 100% INTENSITATE (Siguranță)
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
Ora 21:00 | Trafic estimat: 1734 mașini | Decizie AI: 100% INTENSITATE (Siguranță)
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
Ora 22:00 | Trafic estimat: 1437 mașini | Decizie AI: 100% INTENSITATE (Siguranță)
C:\Users\alega\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-pack
ages\Python311\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature name
s, but RandomForestRegressor was fitted with feature names
  warnings.warn(
Ora 23:00 | Trafic estimat:  829 mașini | Decizie AI: 50% INTENSITATE (Mediu)
================================================
Simulare încheiată cu succes!
```

9. CONCLUZIE

Lucrarea de față a demonstrat viabilitatea și eficiența integrării tehnicilor avansate de Inteligență Artificială în optimizarea infrastructurii urbane, implementând cu succes un sistem hibrid de control pentru iluminatul stradal bazat pe Machine Learning (ML) și Reinforcement Learning (RL).

Proiectul evidențiază faptul că tranziția către concepte de tip *Smart City* poate fi realizată eficient prin soluții software inteligente. Aplicația dezvoltată reprezintă un prototip funcțional scalabil, capabil să reducă amprenta de carbon și costurile municipalităților, garantând în același timp un mediu rutier sigur și protejat.

BIBLOGRAFIE

1. https://streetlighting.sundrax.com/blog/problems-with-street-lighting
2. https://www.kaggle.com/datasets/pooriamst/metro-interstate-traffic-volume
3. https://tvilight.com/ro/case-study/ai-powered-adaptive-street-lighting-at-greeces-most-strategic-motorway/
4. https://www.gdslighting.com/en/adaptive-lighting-how-it-works-and-why-choose-it/
5. https://ieeexplore.ieee.org/document/11019508
6. https://www.scitepress.org/Papers/2022/110403/110403.pdf